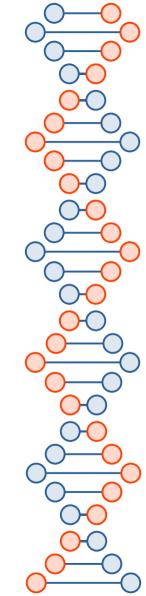


Yet Another Virtual Room Jetson AI Ambassador

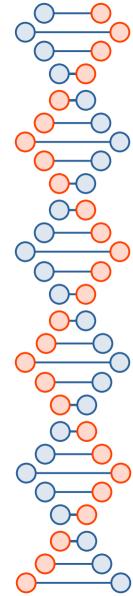


#### Обо мне:

Я много лет работаю старшим преподавателем Южного Федерального университета и преподаю курсы по многим предметам, включая «Технологии машинного обучения».

Кроме того, я преподаю курс AI в Samsung IT Academy https://myitacademy.ru/ai/ai\_lectures/

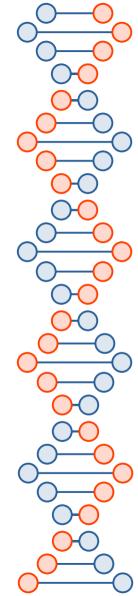
В настоящее время пишу кандидатскую диссертацию по AI/ML.



Идея.

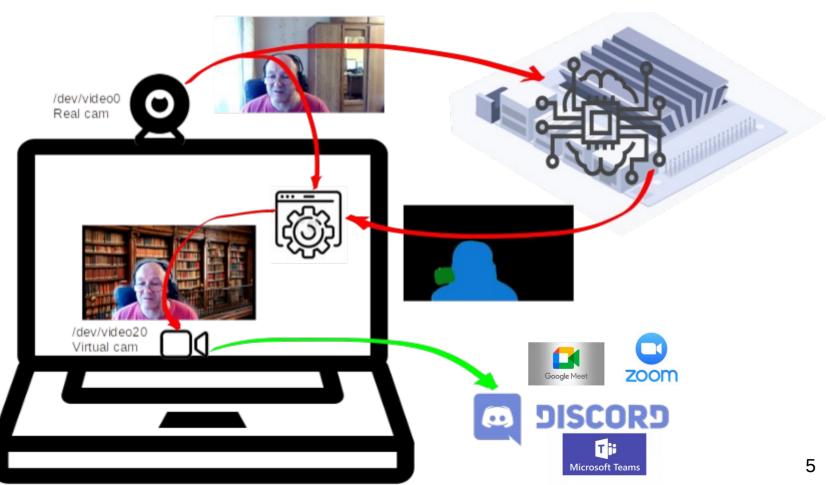
Я хотел разработать практически полезное приложение, которым мог бы пользоваться я сам и любой человек. Мне, в моей преподавательской деятельности необходима возможность замены заднего фона при общении через программы удаленного общения. К сожалению не все программы могут это делать. Например MS Teams for linux или Discord не реализуют такой функциональности.

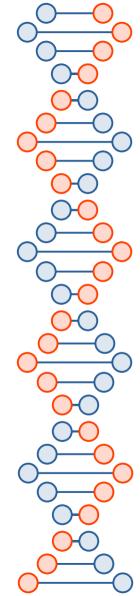
Поэтому я решил получить полезное велью от от покупки Nvidia Jetson Nano и в качестве проекта написать приложение, которое это делает.



Задачи.

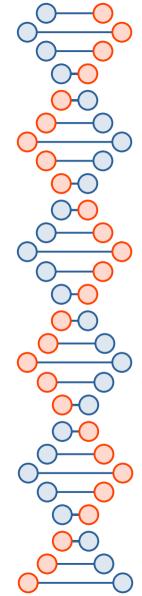
- 1) Захват изображений с веб-камеры как серию изображений
- 2) Семантическая сегментация объектов на изображениях
- 3) Генерация маски для изображения по цветам
- 4) Генерация нового изображений по маскированным изображениям из (1)
- 5) Передать изображения из (4) в виртуальное (aka fake, loopback и т. д.) видеоустройство v4l2loopback
- 6) Настроить программное обеспечение для удаленной связи, чтобы использовать видеоустройство loopback в качестве моей видеокамеры.





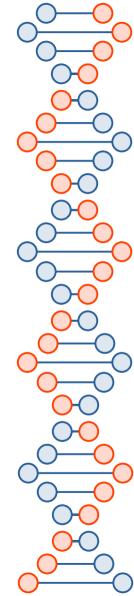
#### Вызовы.

- Мой ноутбук, как и большинство ноутбуков, слишком медленный для потоковой сегментации нужно передать обработку на другое устройство
- Для нормального функционирования программы скорость предсказания должна быть менее 50 мс. Для Jetson это слишком быстро - необходима оптимизация
- Благодаря распределенному способу работы потребуется максимально возможный асинхронный и отказоустойчивый программный код.



#### Программное и аппаратное обеспечение.

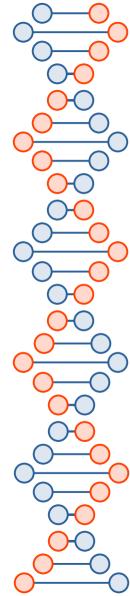
- Ноутбук (client)
  - Dell 5491 i5-8300H 2.3Gh/2\*8G/SSD256
  - OpenSUSE Leap 15.3, 5.3.18-59.19-default
  - Python 3.6.13 on bare metal
- Jetson Nano (server)
  - Jetson B01 NANO 2G
  - Ubuntu 18.04.6 LTS, 4.9.201-tegra
  - Python 3.6.9 on bare metal



#### Реализация.

Клиентское приложение состоит из двух модулей **ui.py** и **main.py**. Исходный код https://github.com/d-yacenko/YAVR/tree/main/client

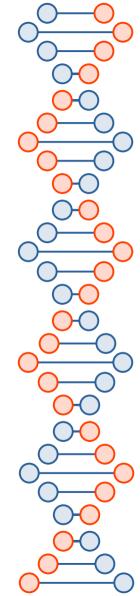
- В **ui.py** нет ничего интересного это просто графический пользовательский интерфейс, написанный на tkinter, работающий с конфигурационным файлом и запускающий с выбранными параметрами **main.py**
- **main.py** выполняет более важные задачи
  - загружает модуль v4l2loopback (необходимо настроить sudoers для текущего пользователя)
  - покадровый захват с веб-камеры и передача кадров с помощью HTTP-запроса на веб-сервер
    Jetson для сегментации. Здесь нужно ограничить запрос по времени, чтобы добиться работы в
    реальном времени, и учесть возможность того, что сервер не предоставит результат.
  - получает изображение маски с сервера
  - применяет маску для удаления фона, накладывает статический или динамический фон, применяет специальные эффекты



#### Реализация сервера.

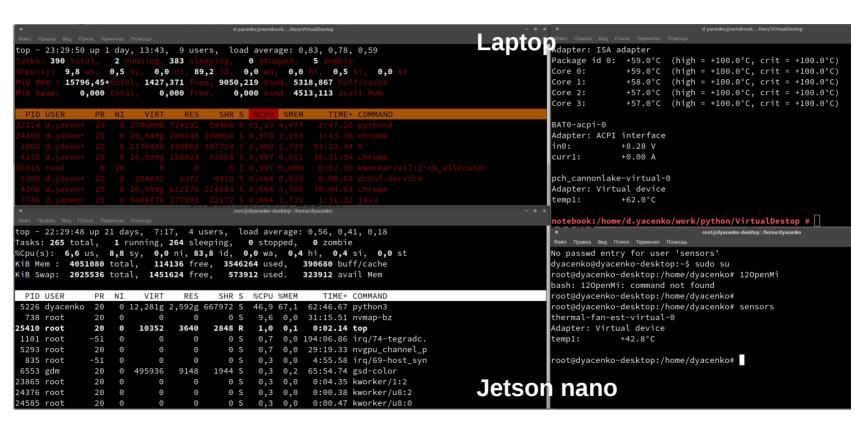
Source code - https://github.com/d-yacenko/YAVR/tree/main/server . Серверная часть часть приложения состоит из двух модулей server.py и segmentation.py

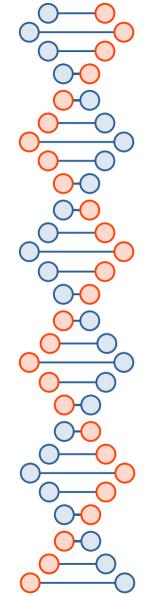
- **server.py** представляет собой реализацию веб сервера, где в обработчике post запроса получается входное изображение и запускается модуль **segmentation.py** для его обработки и получения маски. Здесь используются потоки для оптимизации.
- **segmentation.py** наиболее интересный модуль во всем проекте. Для сегментации была выбрана pretrained network deeplabv3\_mobilenet\_v3\_large из проекта torchvision. Эта сеть показала наибольшую скорость сегментации. Я решил не обучать собственную сеть,т.к. я вряд ли бы получил более высокую скорость, и именно скорость критически важна в приложении. Кроме того был предпринят еще ряд методов для ускорения inference:
- Использование неблокирующей pinned memory для ускорения переноса данных GPU → CPU
- Понижение разрядности данных перед переносом на СРИ
- Вычисление argmax также на GPU
- Очистка памяти на GPU после inference
- Note. По ряду причин необходимо было сохранять input image и сгенерированную маску как файл. Для ускорения чтения / записи предохранения storage от выжигания был использован ramdisk. Для его монтирования в /etc/fstab была добавлена запись: **tmpfs /RAM tmpfs size=10m 0 0**



#### Результаты.

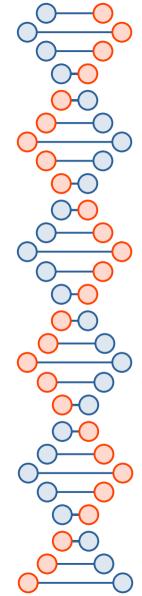
- Было создано MVP приложения для бюджетного роеалтайм потоковой обработки видео
- Исходный код опубликован https://github.com/d-yacenko/YAVR.git
- Видео демонстрацию можно посмотреть тут: https://drive.google.com/file/d/1VlaSLGa5P0YtwAdNDjHJI9W7D7Tcl3PS/ view?usp=sharing
- Получившееся приложение полезно мне, имеет самостоятельную ценность, а также может быть реализовано как стартап
- Во время работы приложения нагрузка на оборудование и температура компонентов не высоки (см следующий слайд)





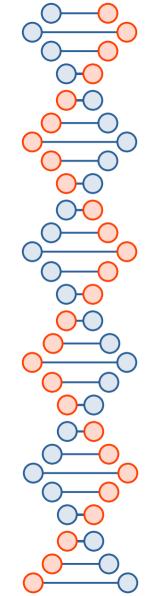
#### Выводы.

- Устройства уровня Jetson Nano можно использовать для не очень больших реальных задач AI/ML.
- Частично Jetson Nano может работать как edge устройство, например, на стыке IoT и AI.



#### Моивация.

- Почему я начал заниматься этим проектом? Мне стало интересно изучить возможности Jetson nano и мои возможности AI/ML на специализированном оборудовании.
- Почему я получаю сертификат Jetson AI Ambassador? В первую очередь мне, как преподавателю сертификат пригодится как подтверждение статуса. Во-вторых, возможно, программа Ambassador даст мне возможность получить другое оборудование Nvidia для исследований например, Xavier NX или какое-то другое.



# Thanks for attention!